

Sesión Invitada Math-In. Industrial Applications IV

Forecasting the energy consumption of multiple buildings

Granada, 09 de junio de 2022

Contenido

- Planteamiento del Problema.
- Metodología y Enfoque.
- Resultados.
- Línea de Investigación.
- Conclusiones.

Planteamiento del Problema

Motivación.

OPORTUNIDAD DE NEGOCIO

Smart Meters

>>>

RETO TECNOLÓGICO

Algoritmos Forecasting

>>>

OBJETIVO COMERCIAL

Monetización Servicios

Principales aplicaciones.

- Optimización de operaciones de **compra y venta de energía**.
- Optimización de los **activos energéticos**.
- Programas de **respuesta a la demanda**.
- **Mantenimiento** predictivo.
- **Analíticas e informes** de consumo de carácter predictivo.

Planteamiento del Problema

Datos.

BBDD anonimizada clientes de Bettergy:

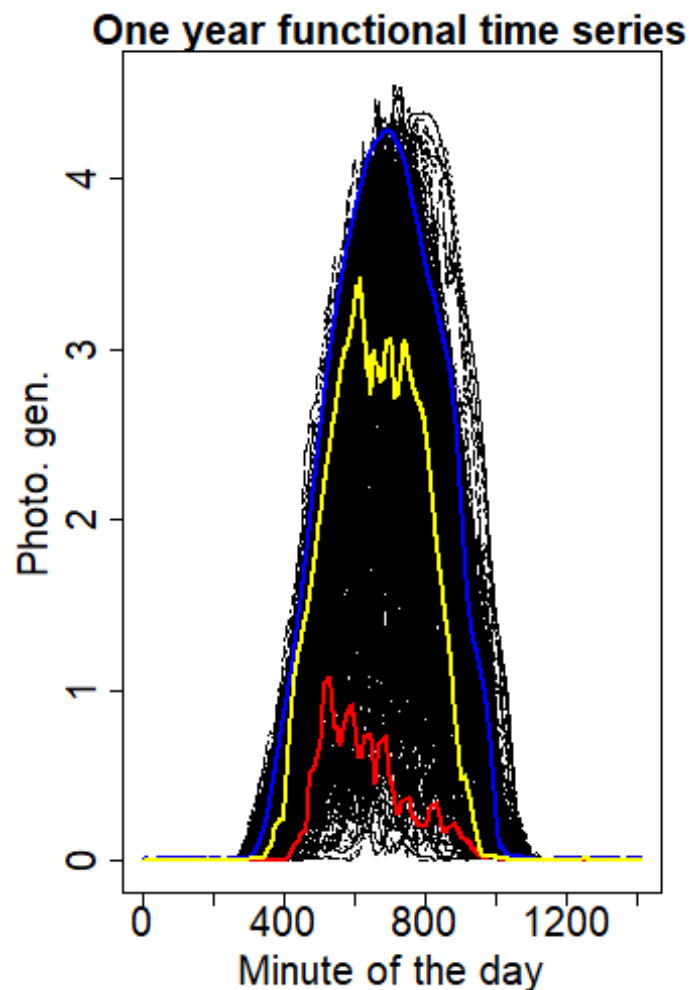
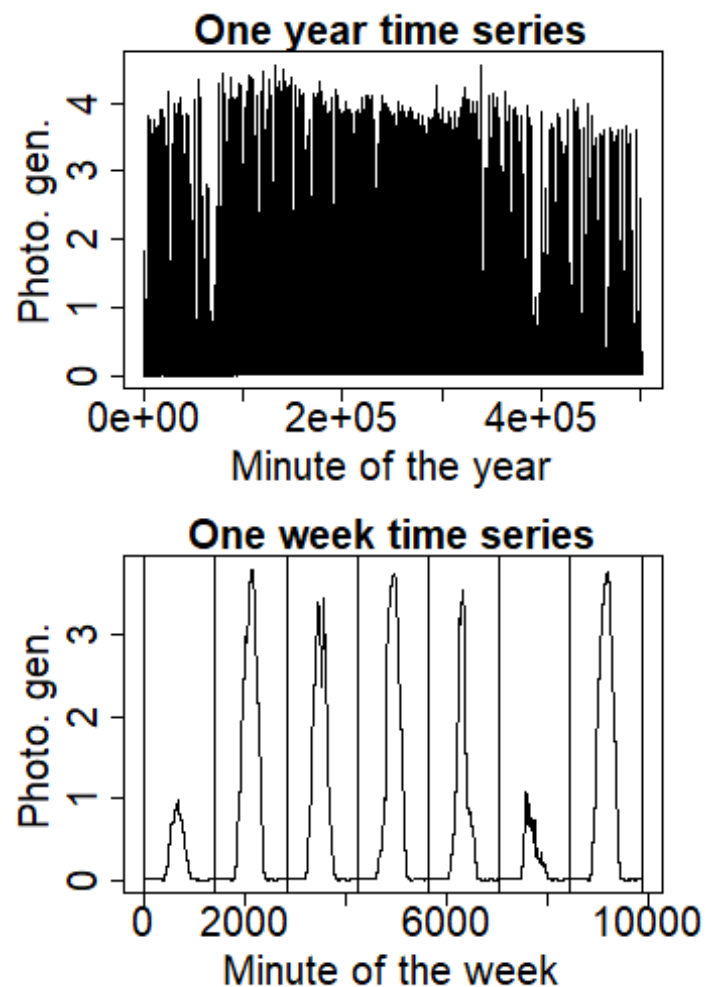
- 499 edificios (industriales, comerciales y residenciales).
- Datos de consumo eléctrico, granularidad horaria, año 2019.

Complejidad de los datos de consumo real. Desafíos:

- 1) El **análisis de múltiples series temporales** de grano fino con comportamientos estacionales/cíclicos.
- 2) La **heterogeneidad** de los patrones diarios **de las variables** de estudio, que pueden variar en magnitud, forma y evolución diaria entre edificios.

Metodología y Enfoque

Análisis de Datos Funcional (FDA).



FDA nos permite centrarnos en el análisis de **curvas o funciones de naturaleza continua** [1] aunque estén recogidas en intervalos de tiempo discretos.

FDA ha demostrado ser **superior a otras técnicas** para resolver problemas en los que los datos tienen naturaleza similar a los recogidos a través de smart meters [2].

Metodología y Enfoque

Versión funcional del método KNN [4].

- Método **Data-driven**. Basado en el concepto de **Envoltorio Funcional**.
- El algoritmo de búsqueda se apoya en el concepto de **Profundidad Funcional** [5].

Modified Band Depth (MBD) [6]. Dada una muestra general de curvas T:

$$MBD(y; Y) = \binom{T}{2}^{-1} \sum_{1 \leq i < j \leq T} \frac{1}{p} \sum_{k=1}^p 1 \left\{ \min\{y_i(k), y_j(k)\} \leq y(k) \leq \max\{y_i(k), y_j(k)\} \right\} \quad (1)$$

- **Proyecciones funcionales KNN** (fKNN) con $1/d$ y pesos exponenciales.

f_1, \dots, f_k : k curvas más cercanas a focal

$d_i = \|f_i - f\|^2$: distancia a focal


$\theta > 0$

$$\hat{p}_k = \frac{\sum_{i=1}^k \frac{1}{d_i} \mathcal{P} f_i}{\sum_{i=1}^k \frac{1}{d_i}}, \quad \text{and} \quad \hat{p}_{k,\theta} = \frac{\sum_{i=1}^k e^{-\theta d_i/d_1} \mathcal{P} y}{\sum_{i=1}^k e^{-\theta d_i/d_1}} \quad (2)$$

Metodología y Enfoque

Versión funcional del método KNN [4].

Ejemplo de Envoltorio (31-12-2019)



¿PREDICCIÓN?

"2020-01-01"

ENVOLTORIO

"2019-02-09"

"2019-11-23"

"2019-12-15"

"2019-01-19"

"2019-01-05"

"2019-12-28"

"2019-01-12"

"2019-11-10"

"2019-12-14"

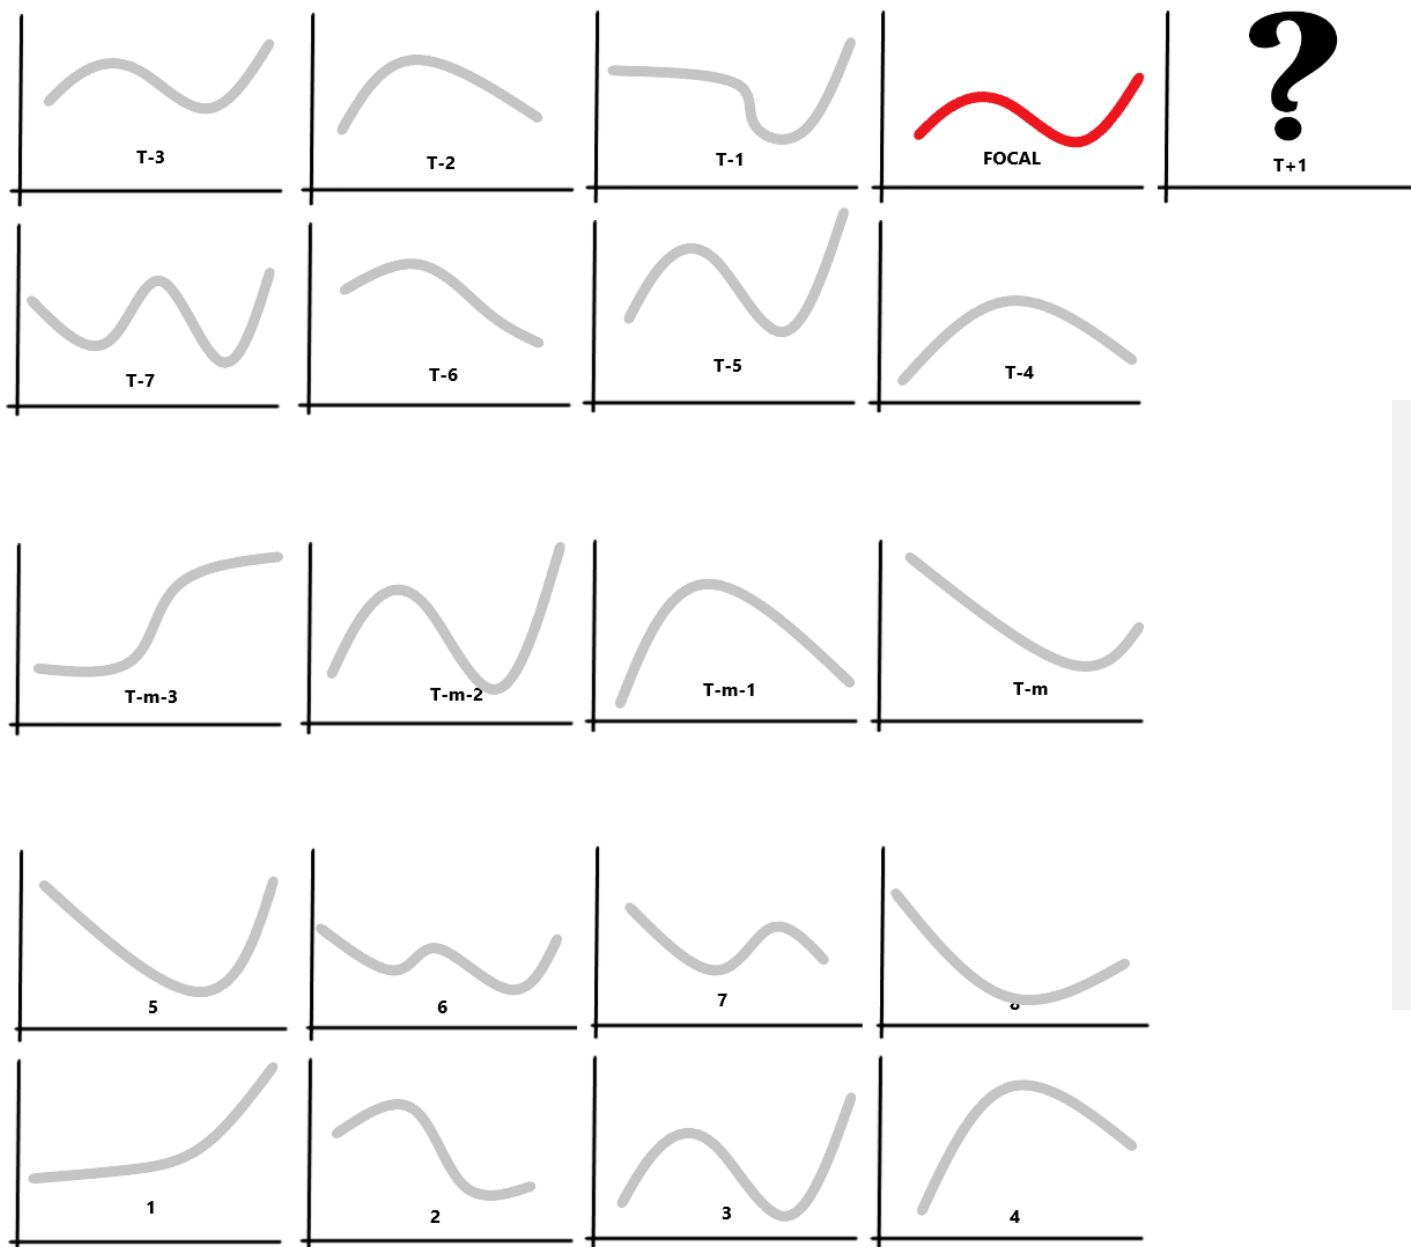
"2019-12-01"

"2019-12-09"

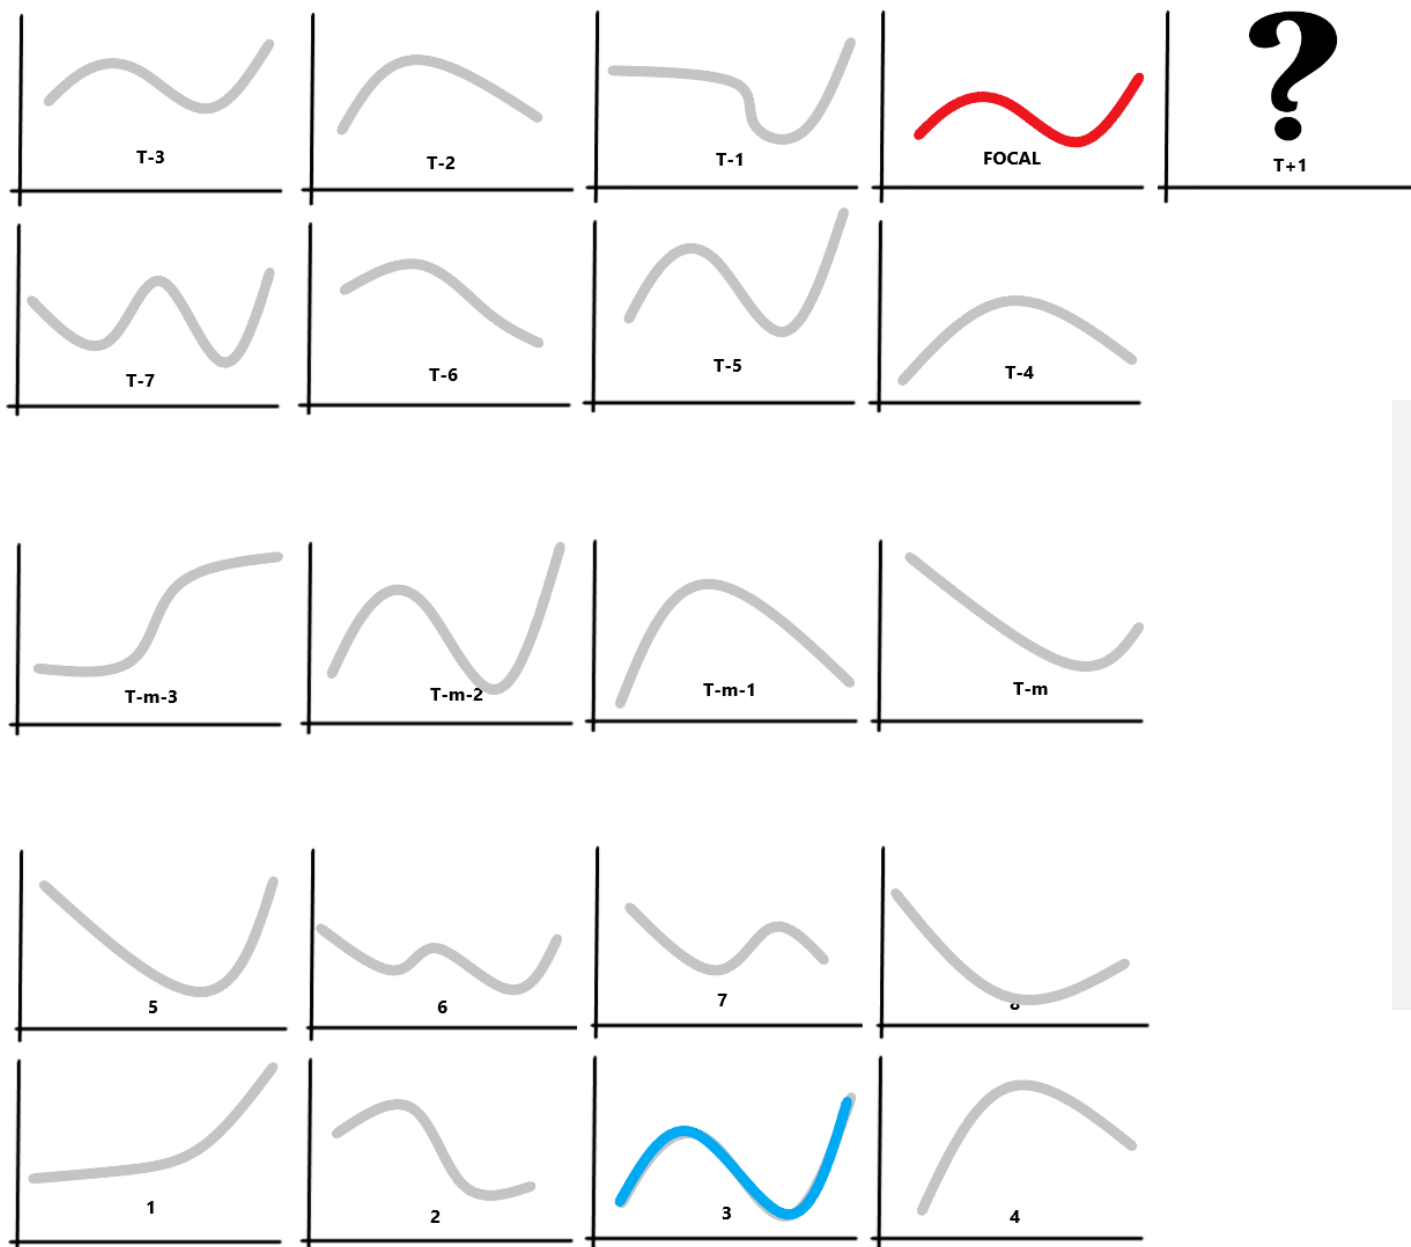
"2019-02-02"

"2019-11-19"

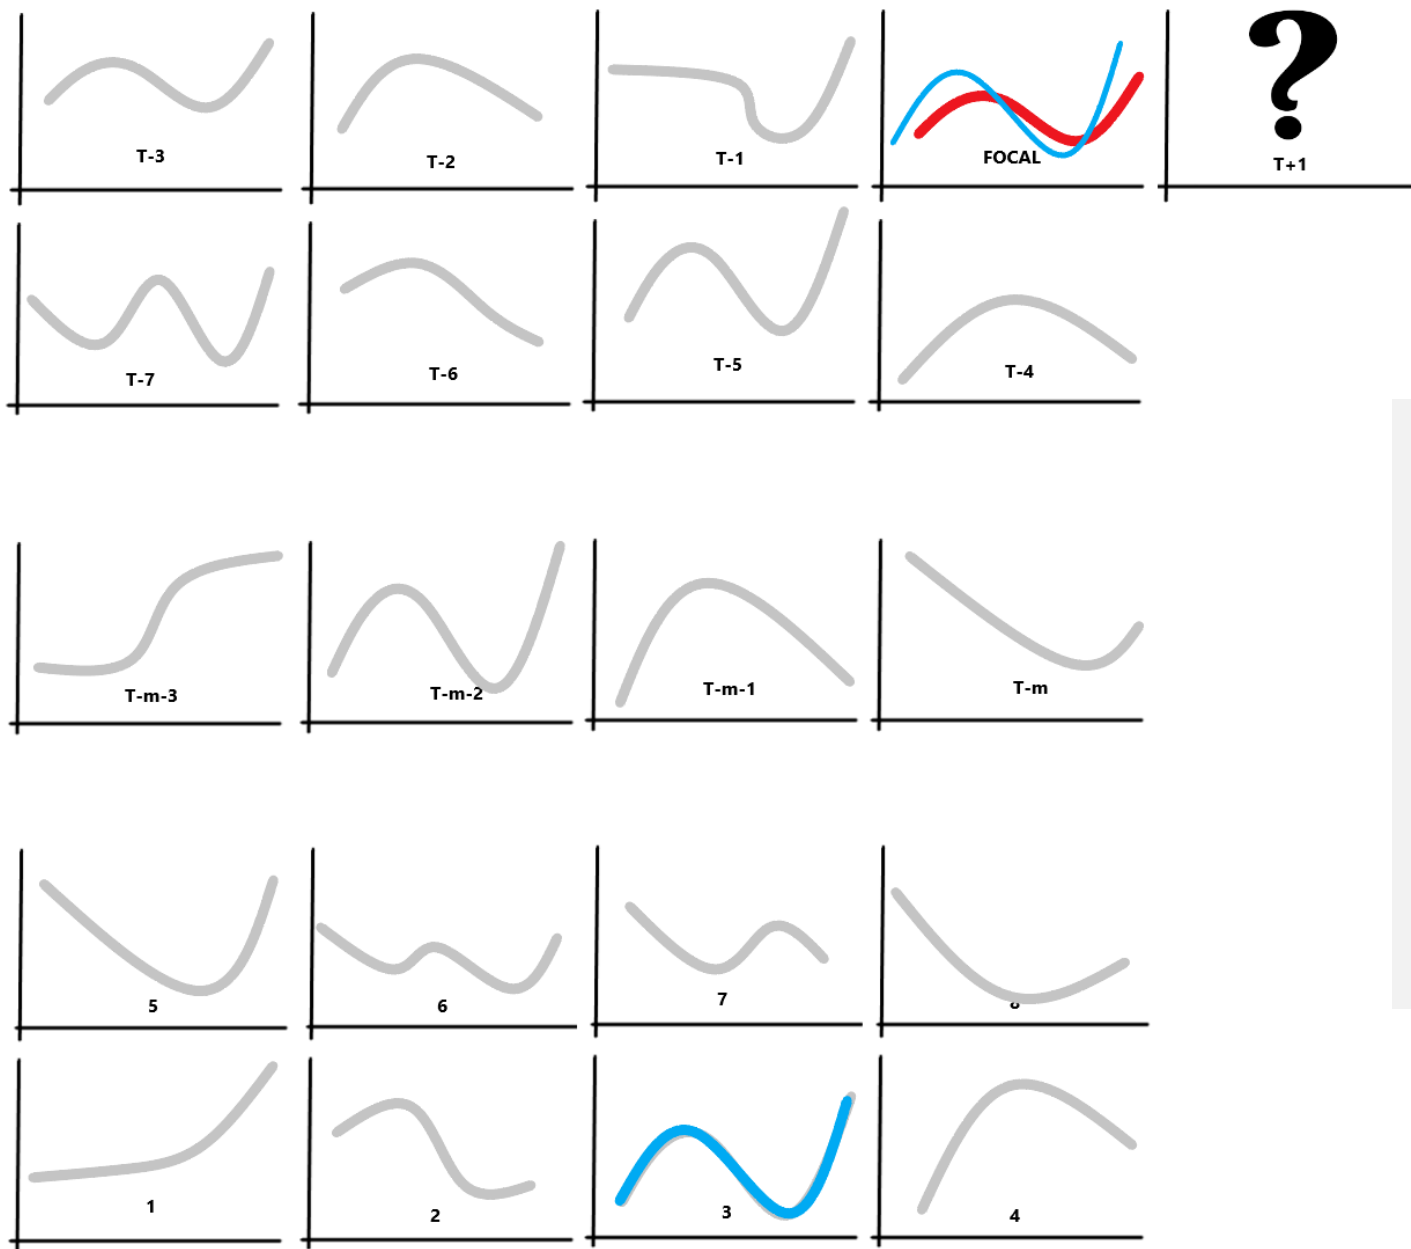
"2019-12-07"



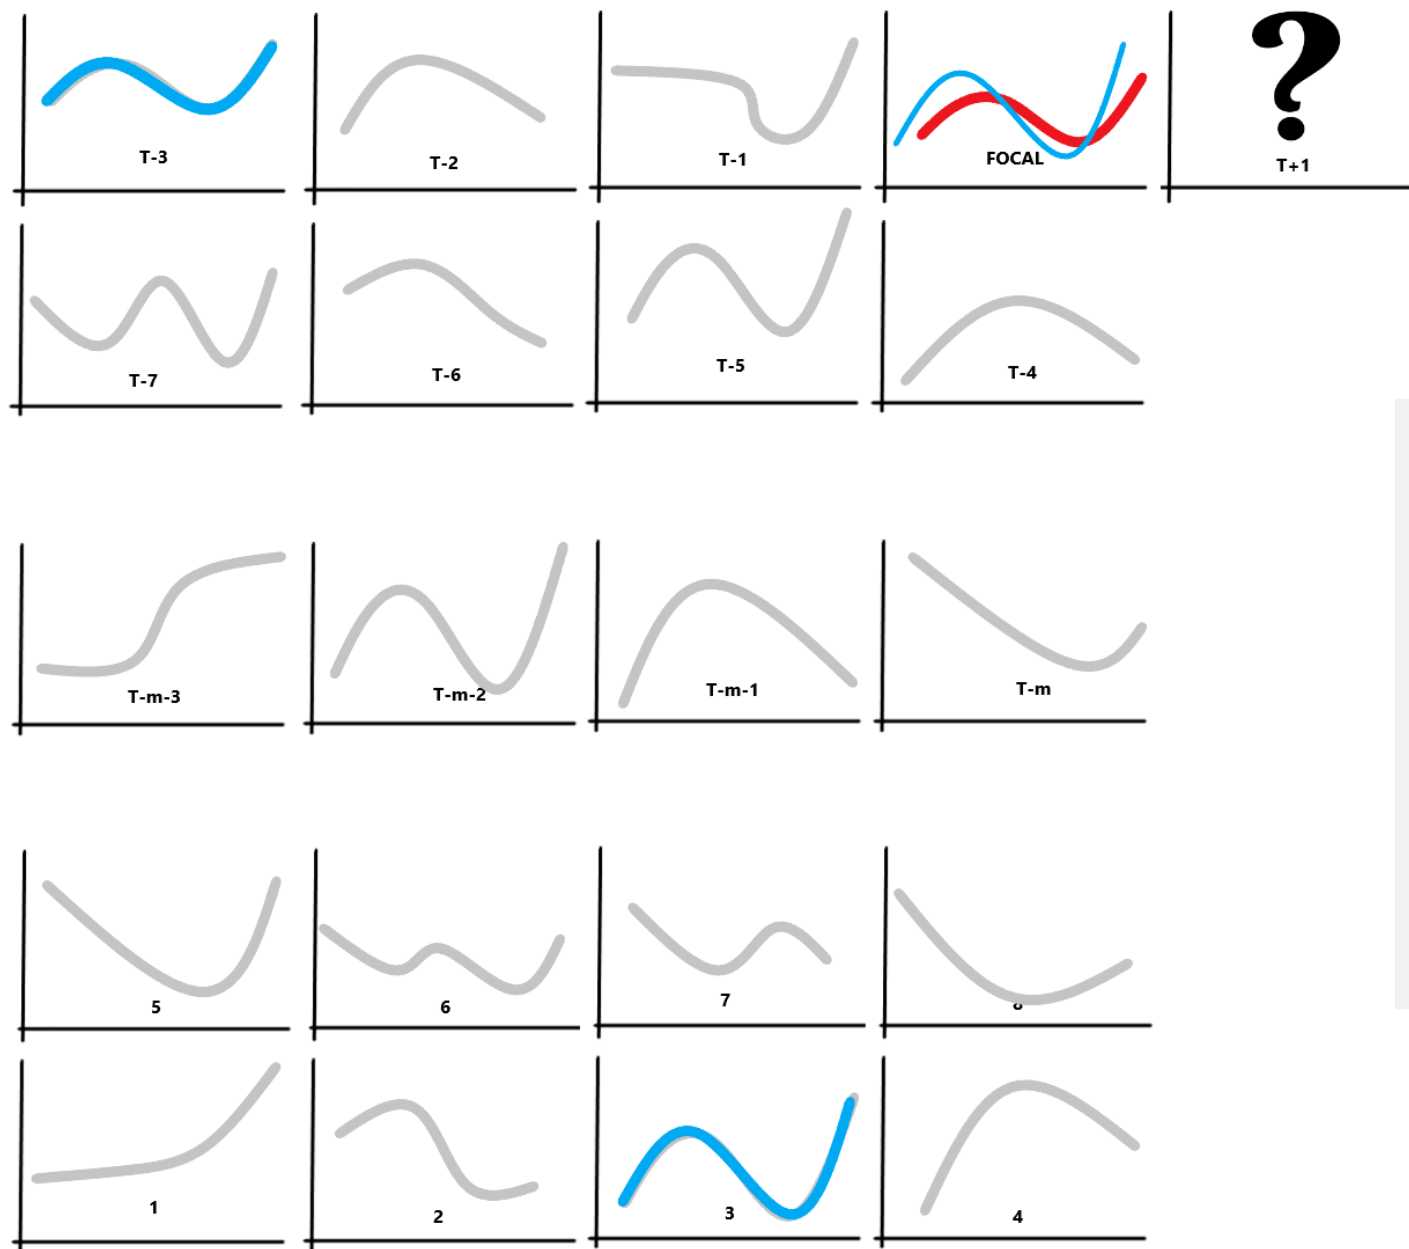
**Depth-based
functional
time series
forecasting**



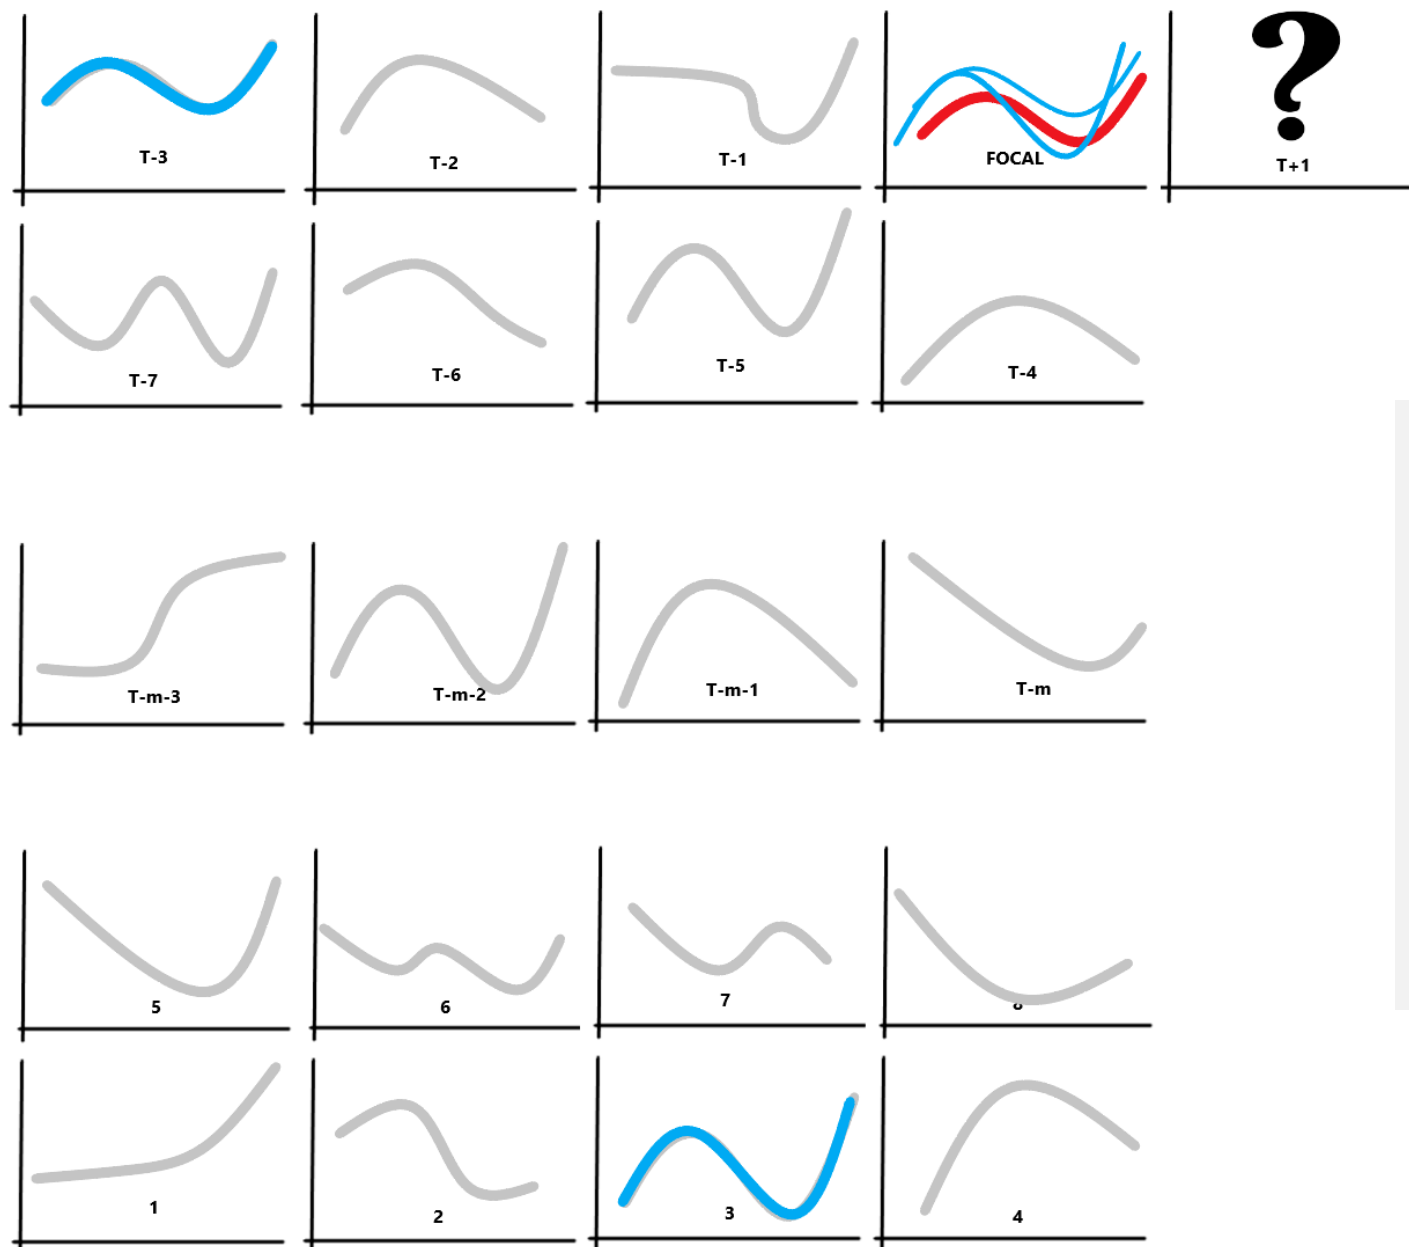
**Depth-based
functional
time series
forecasting**



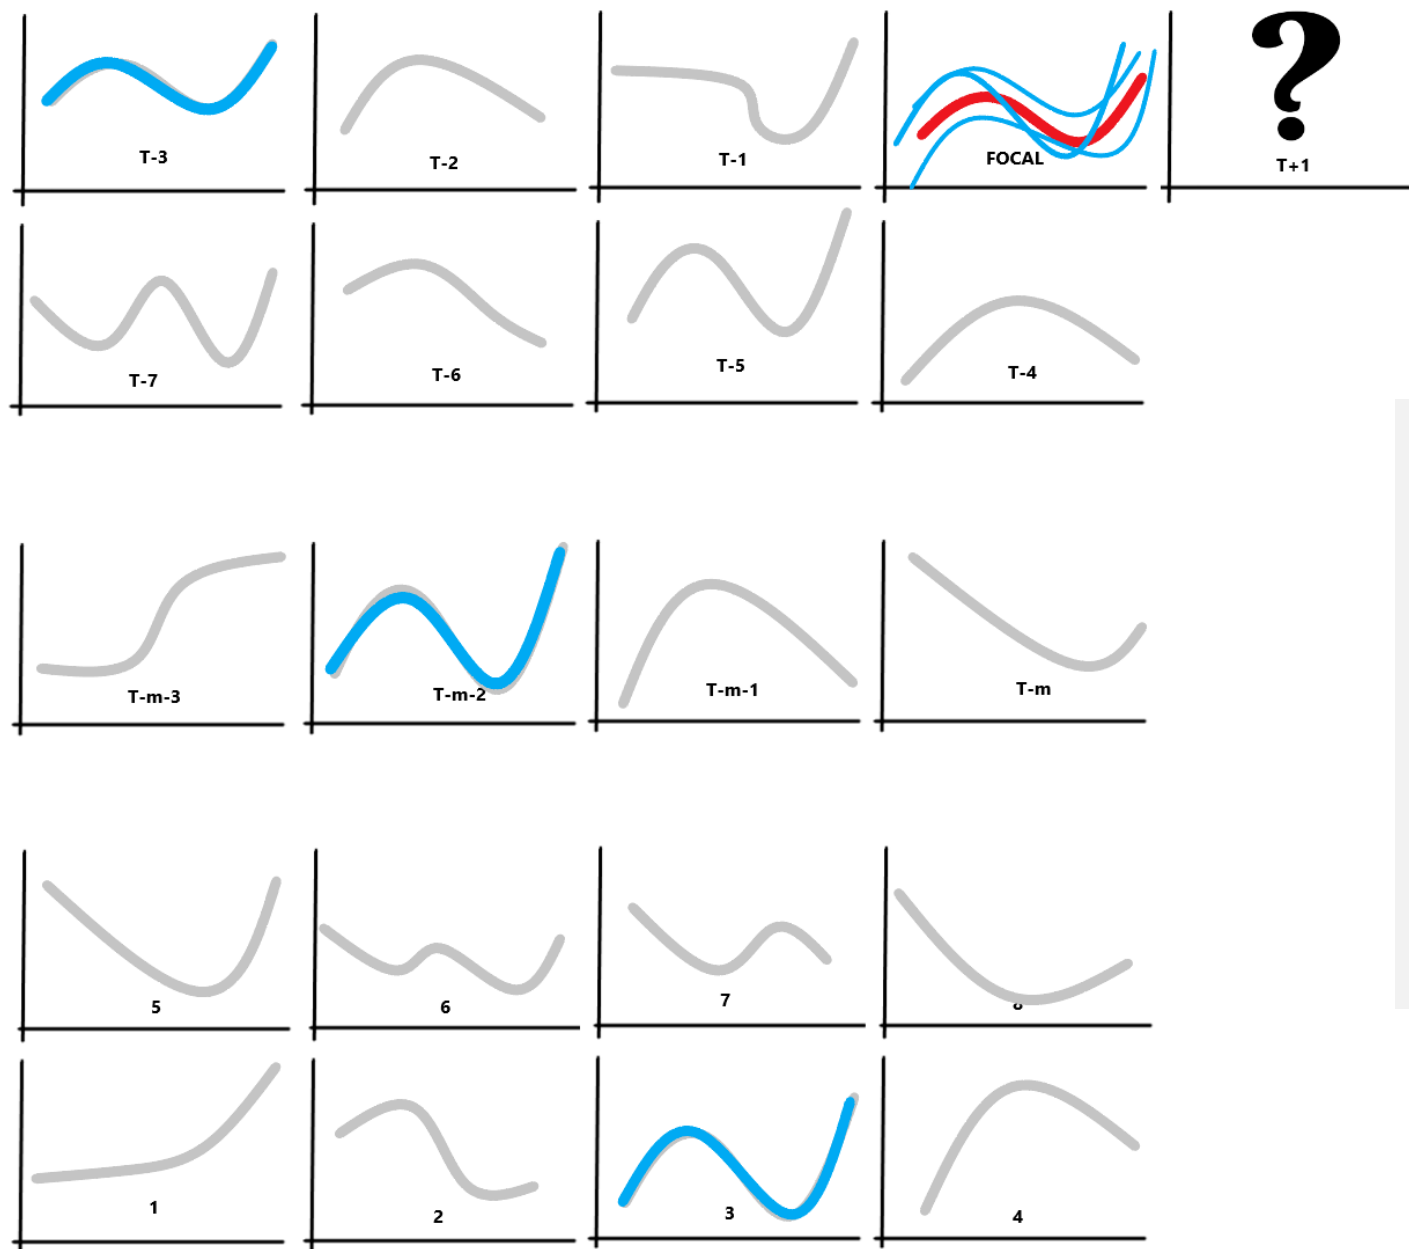
**Depth-based
functional
time series
forecasting**



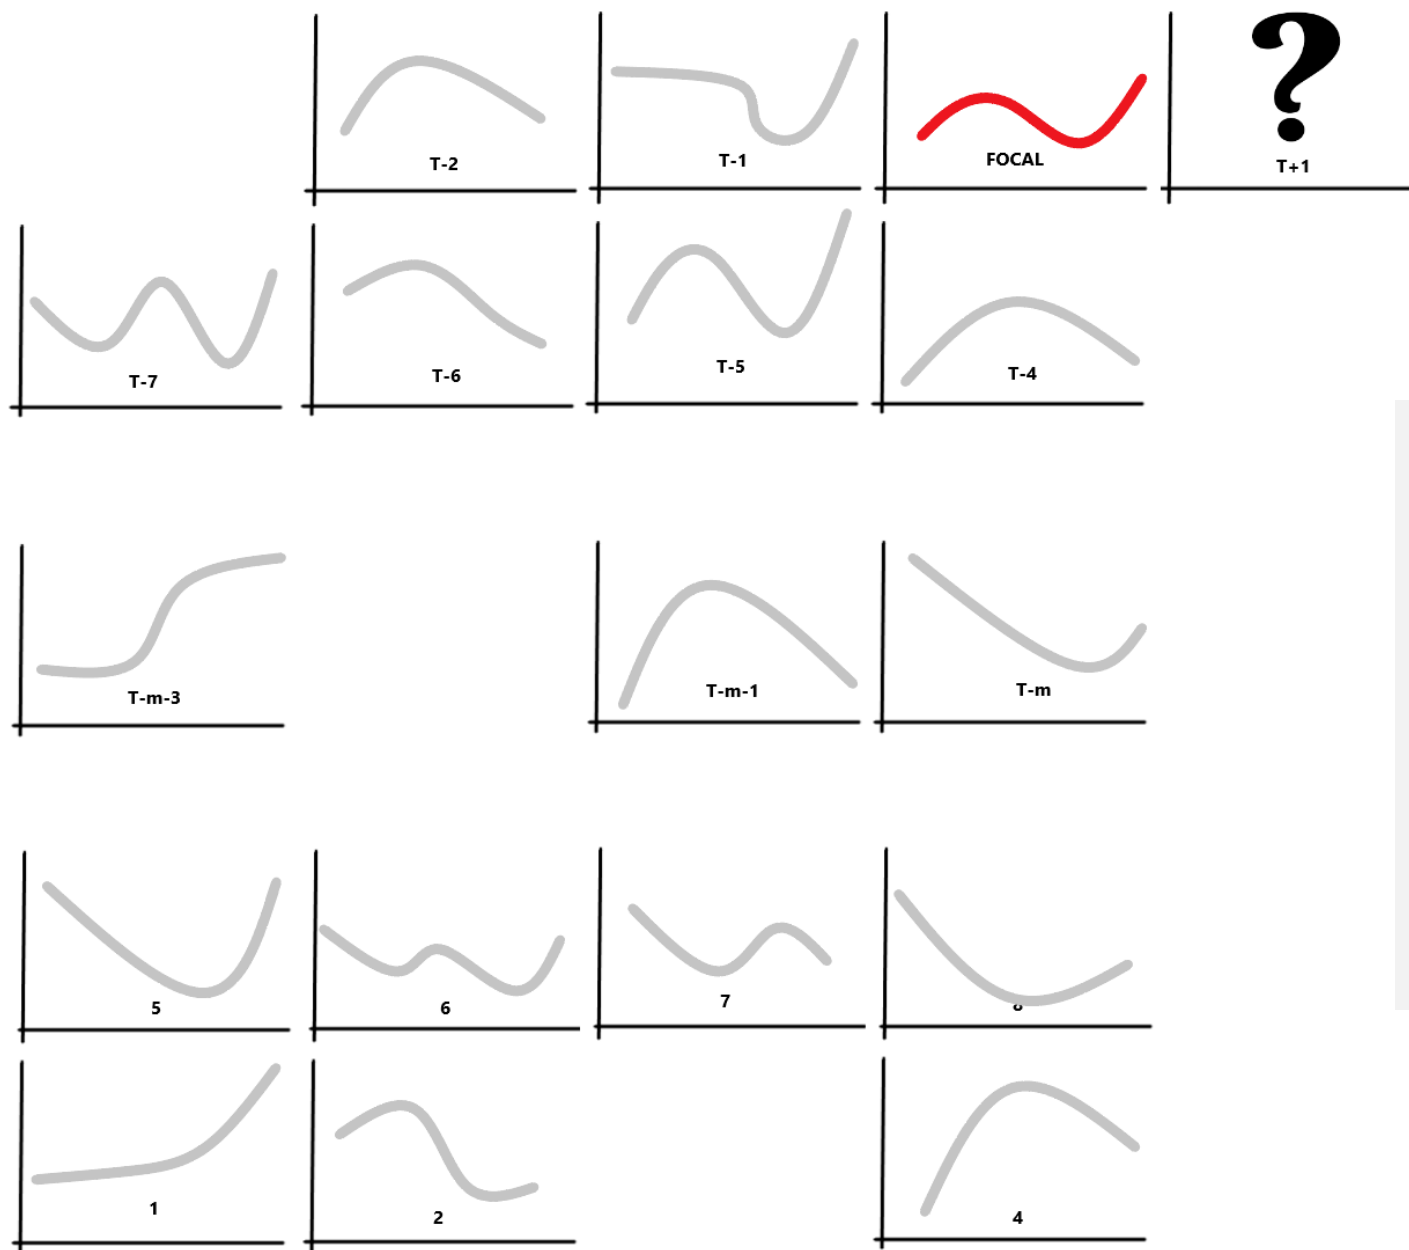
**Depth-based
functional
time series
forecasting**



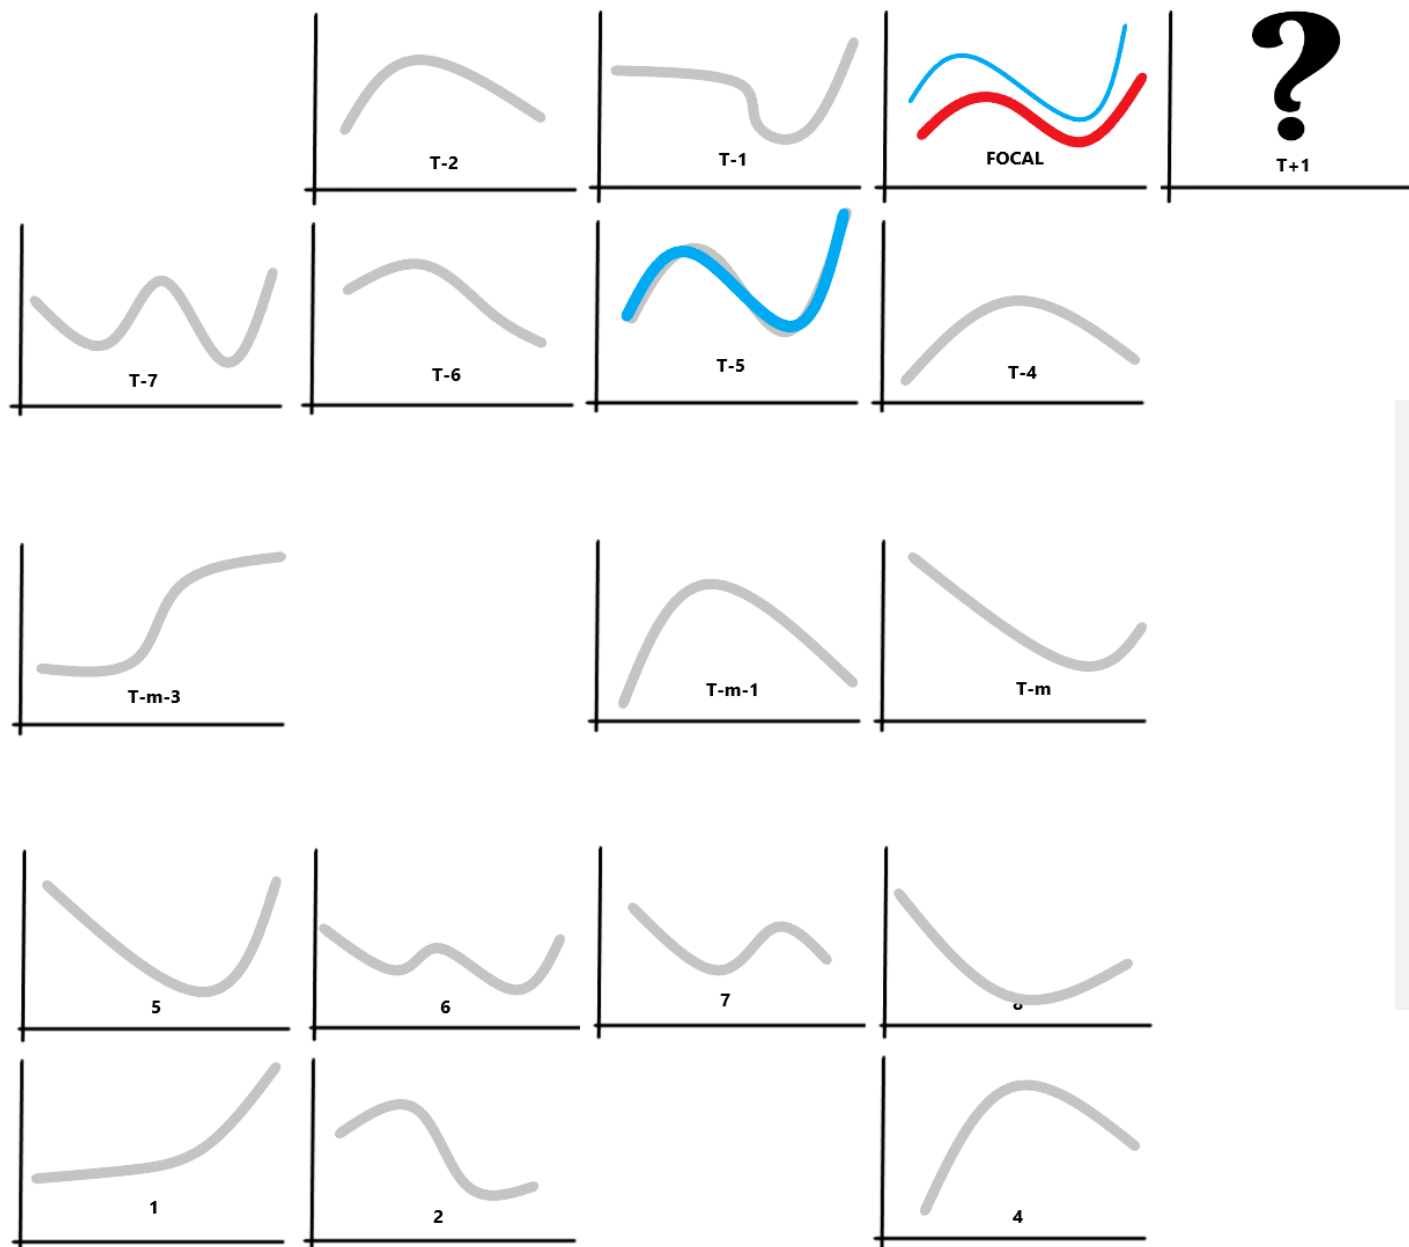
**Depth-based
functional
time series
forecasting**



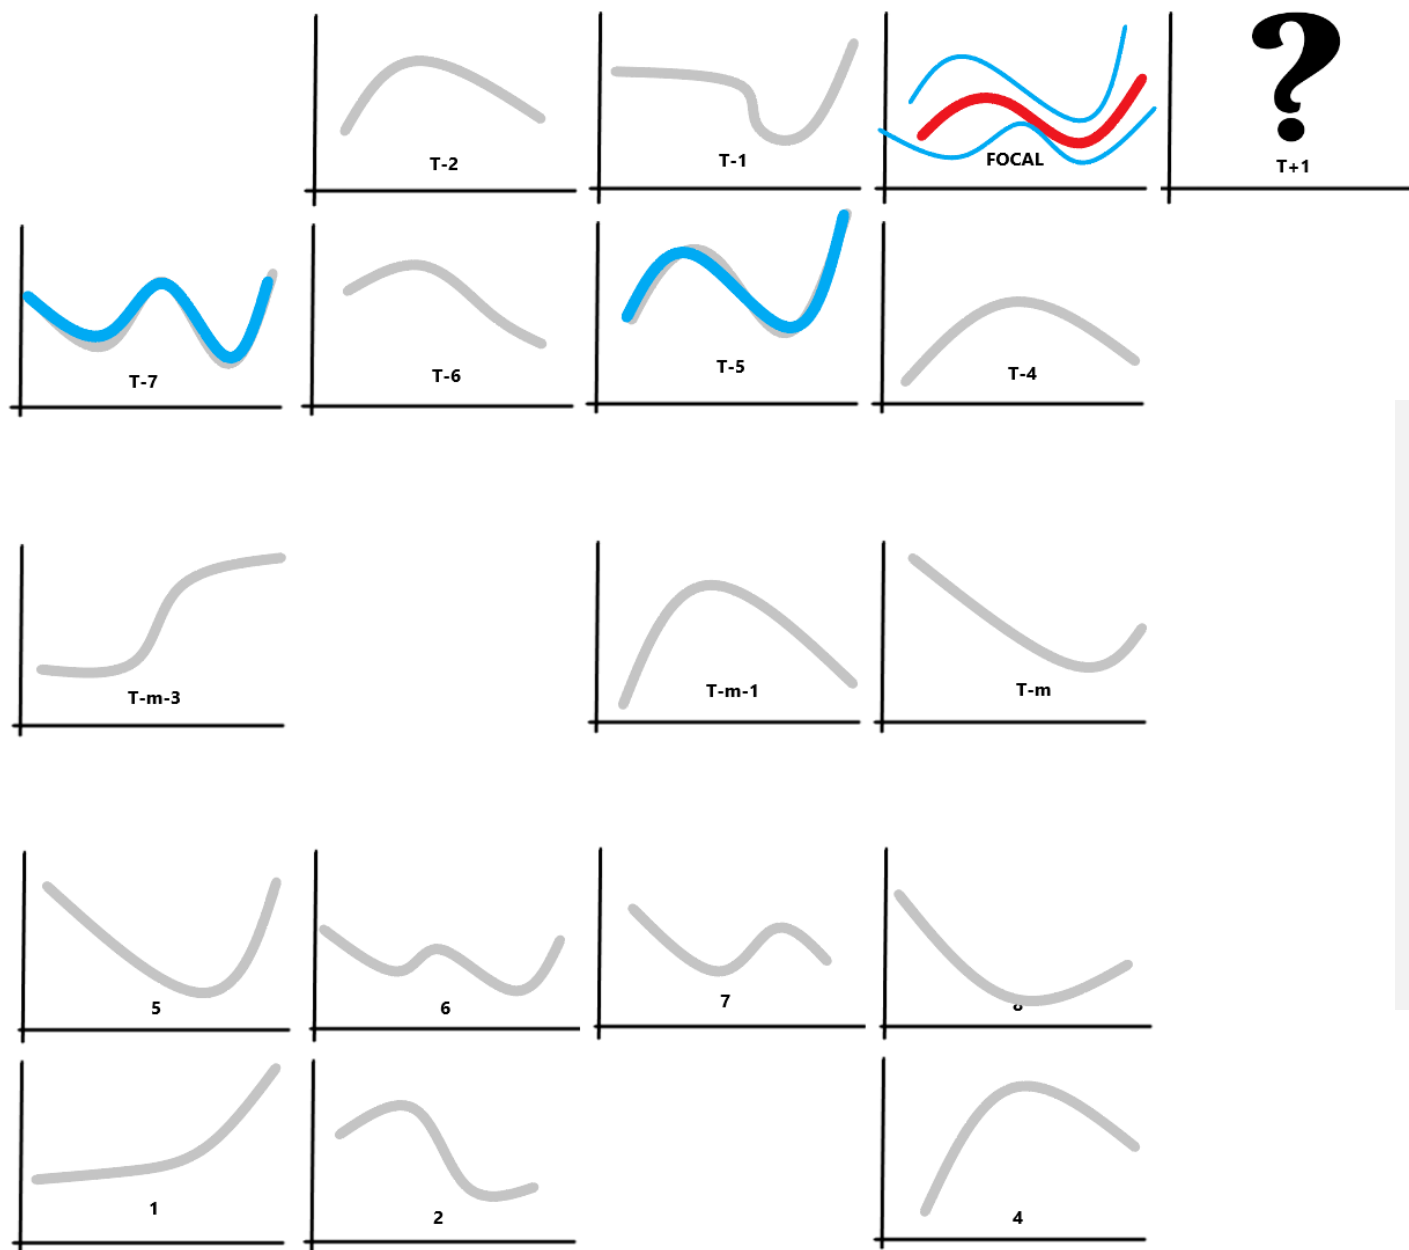
**Depth-based
functional
time series
forecasting**



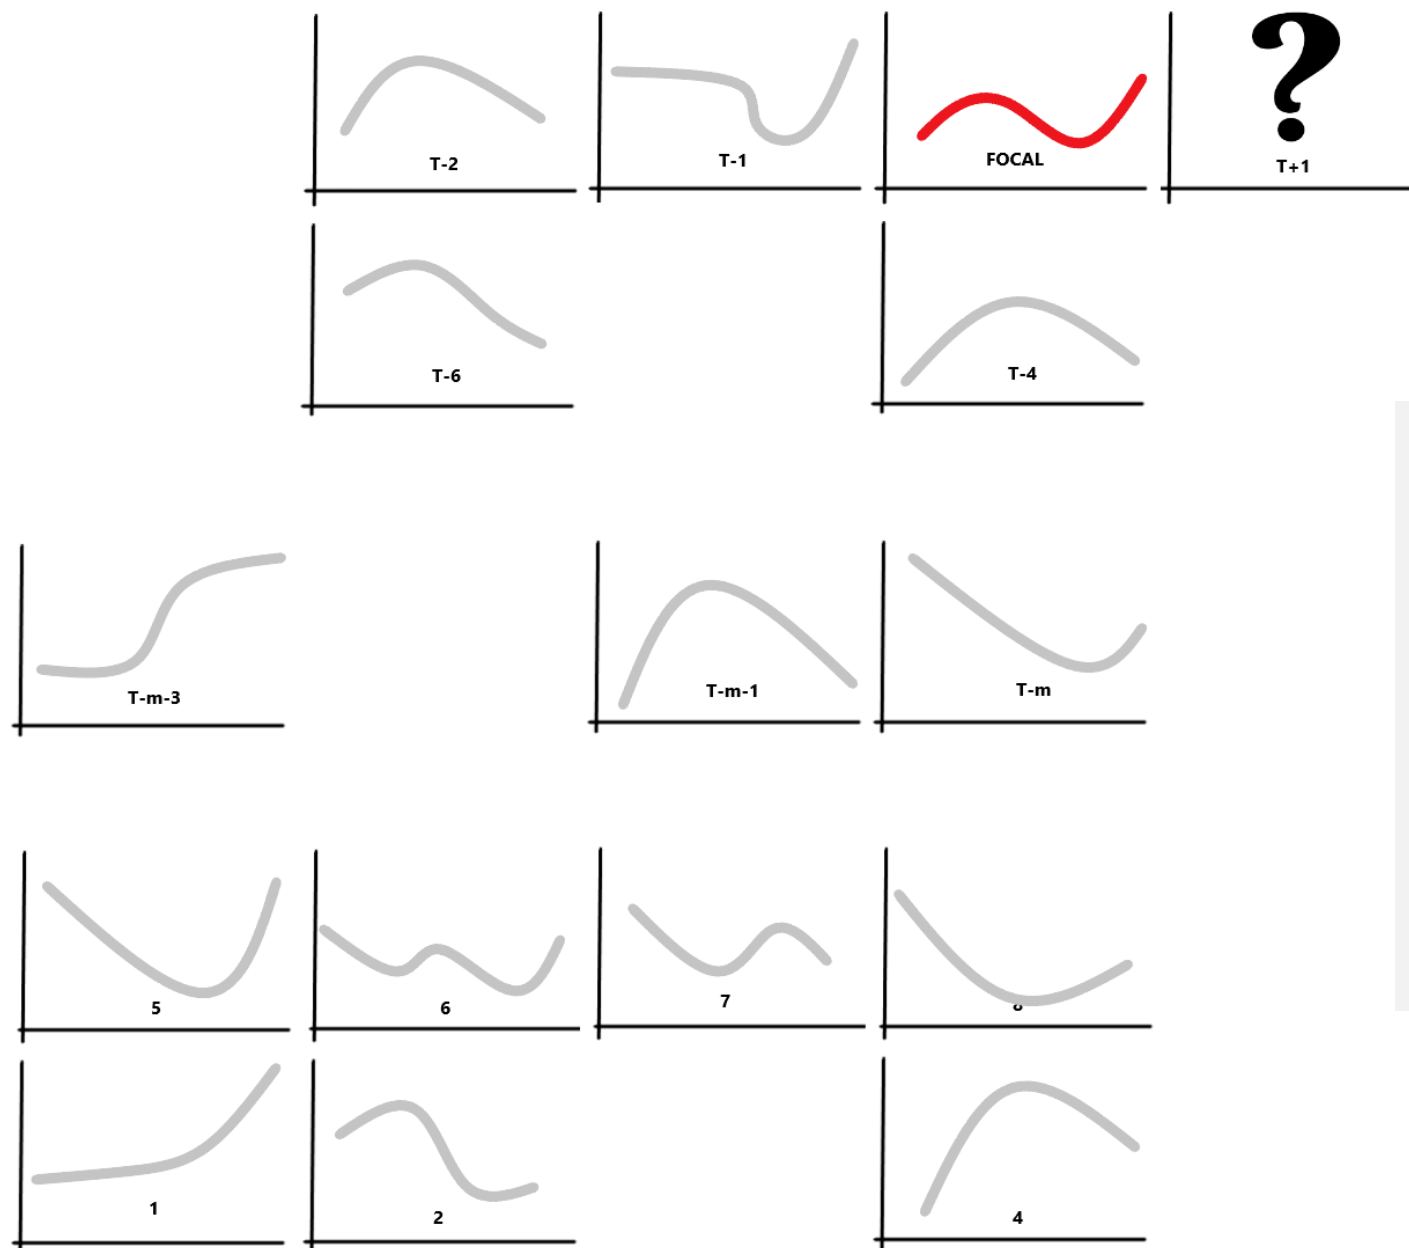
**Depth-based
functional
time series
forecasting**



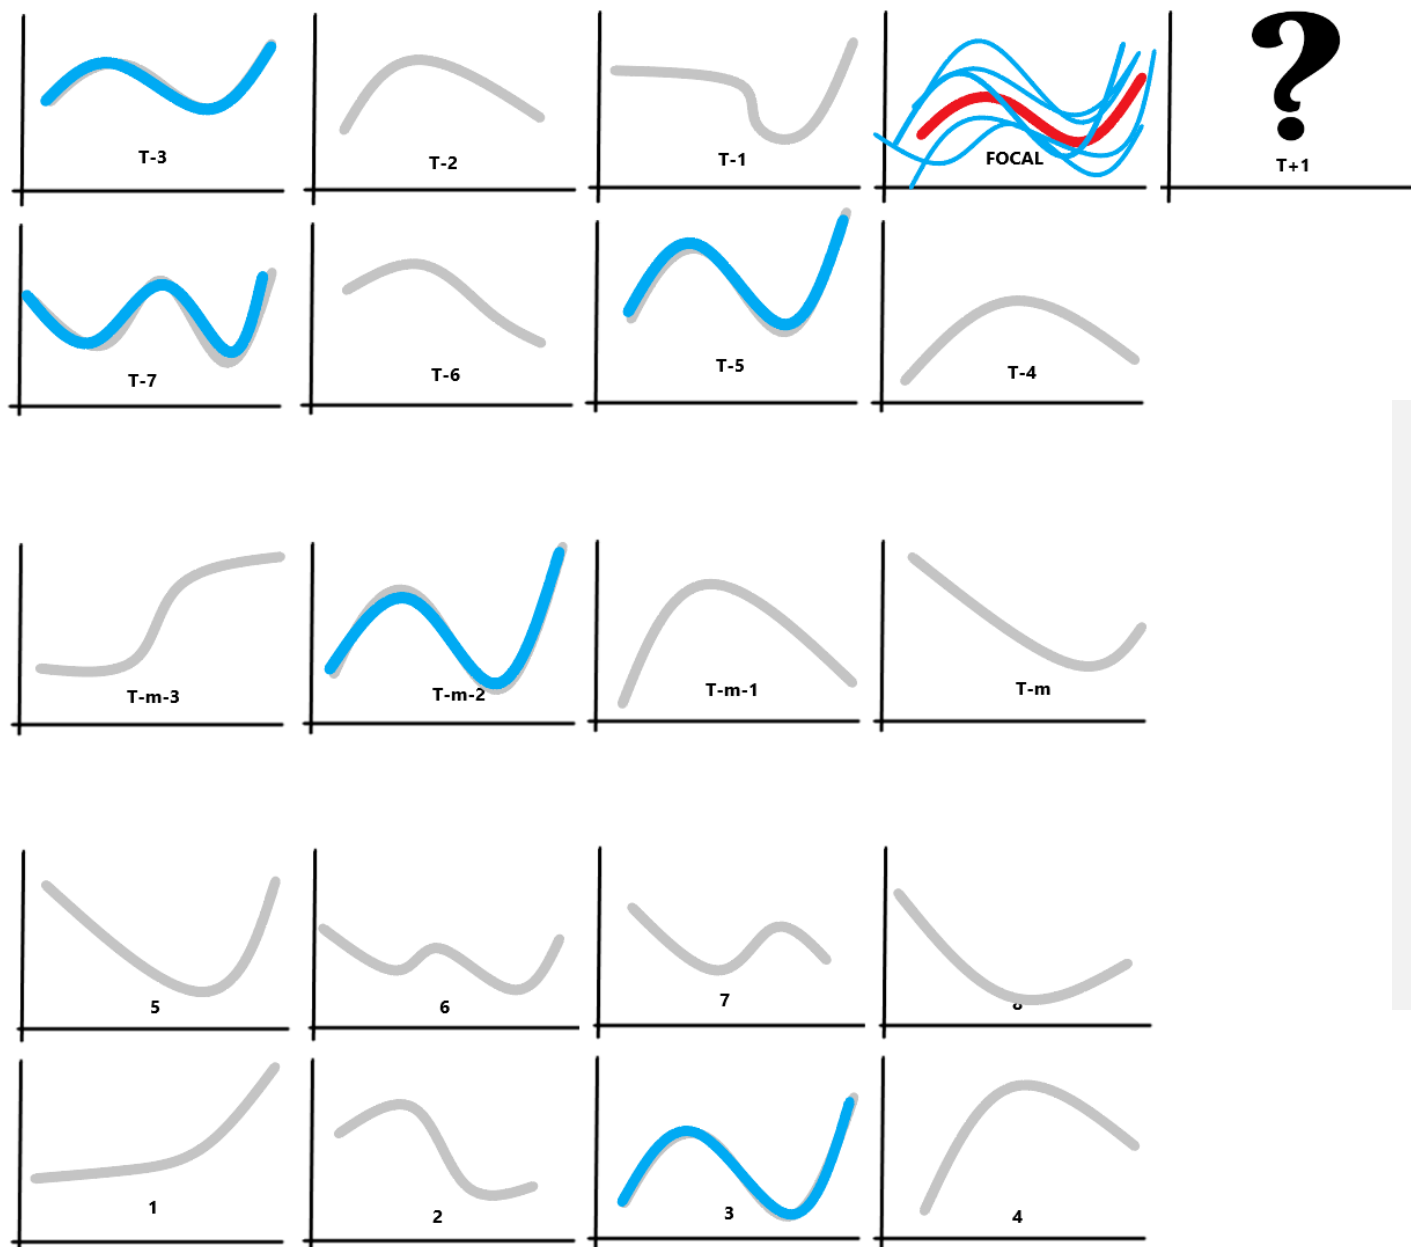
**Depth-based
functional
time series
forecasting**



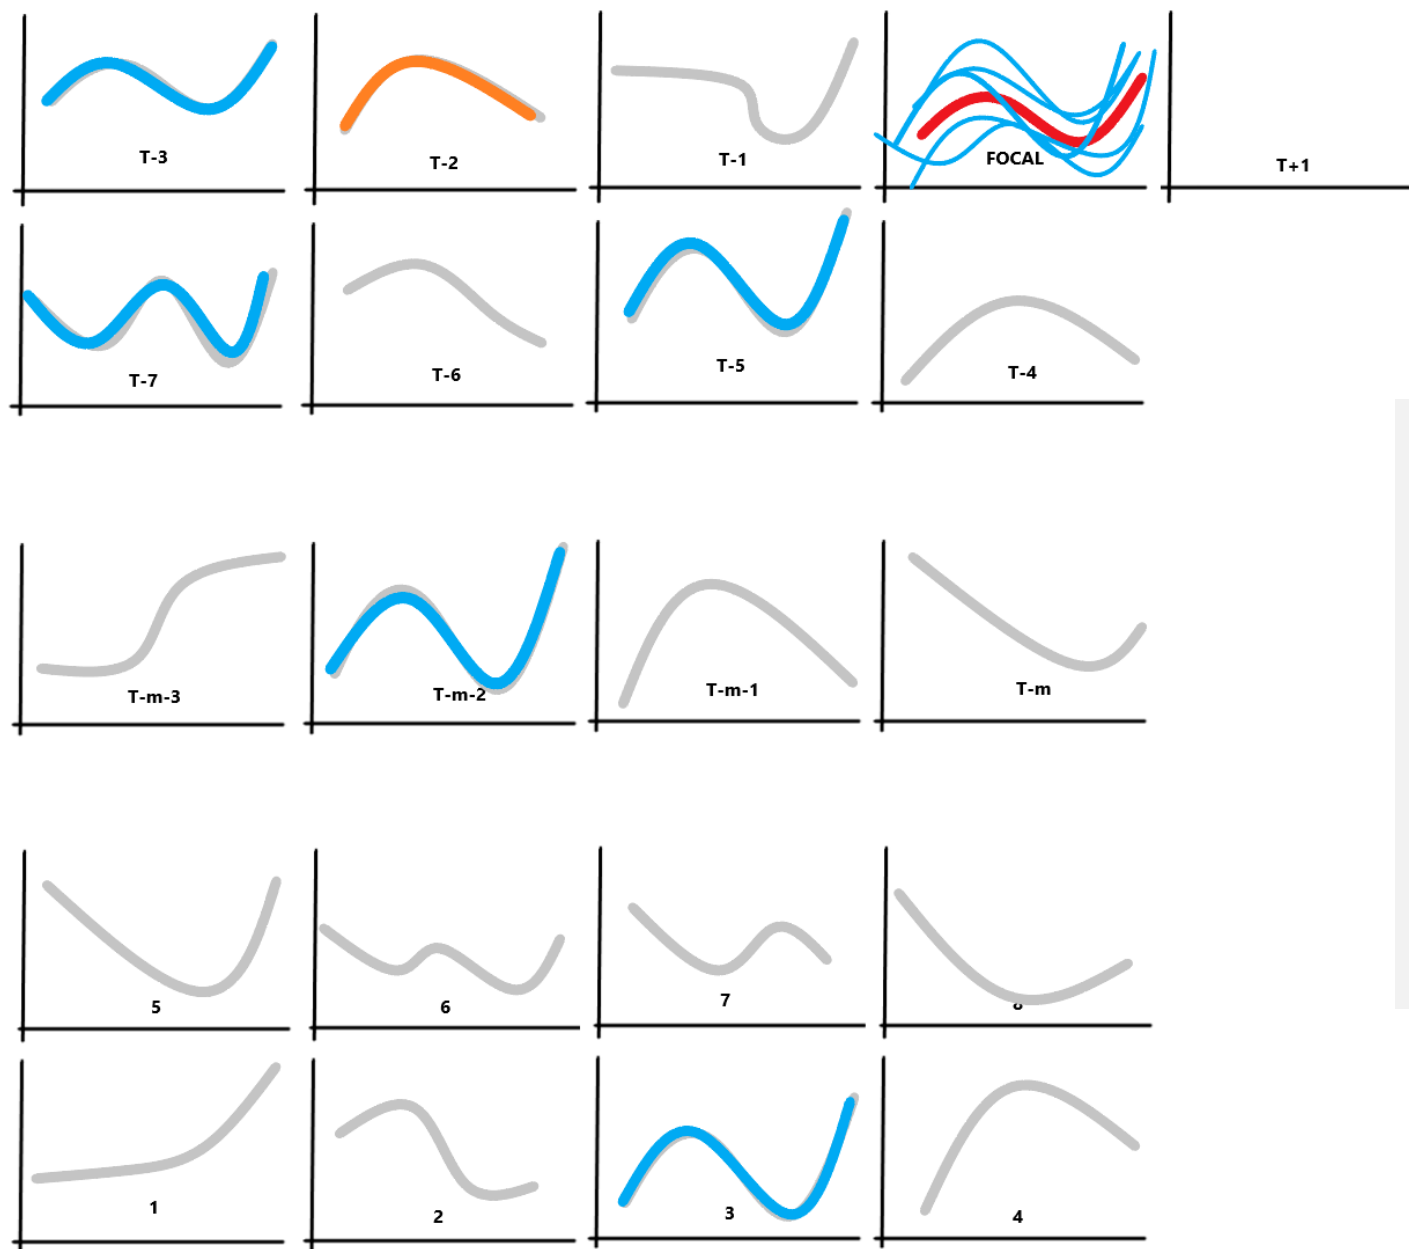
**Depth-based
functional
time series
forecasting**



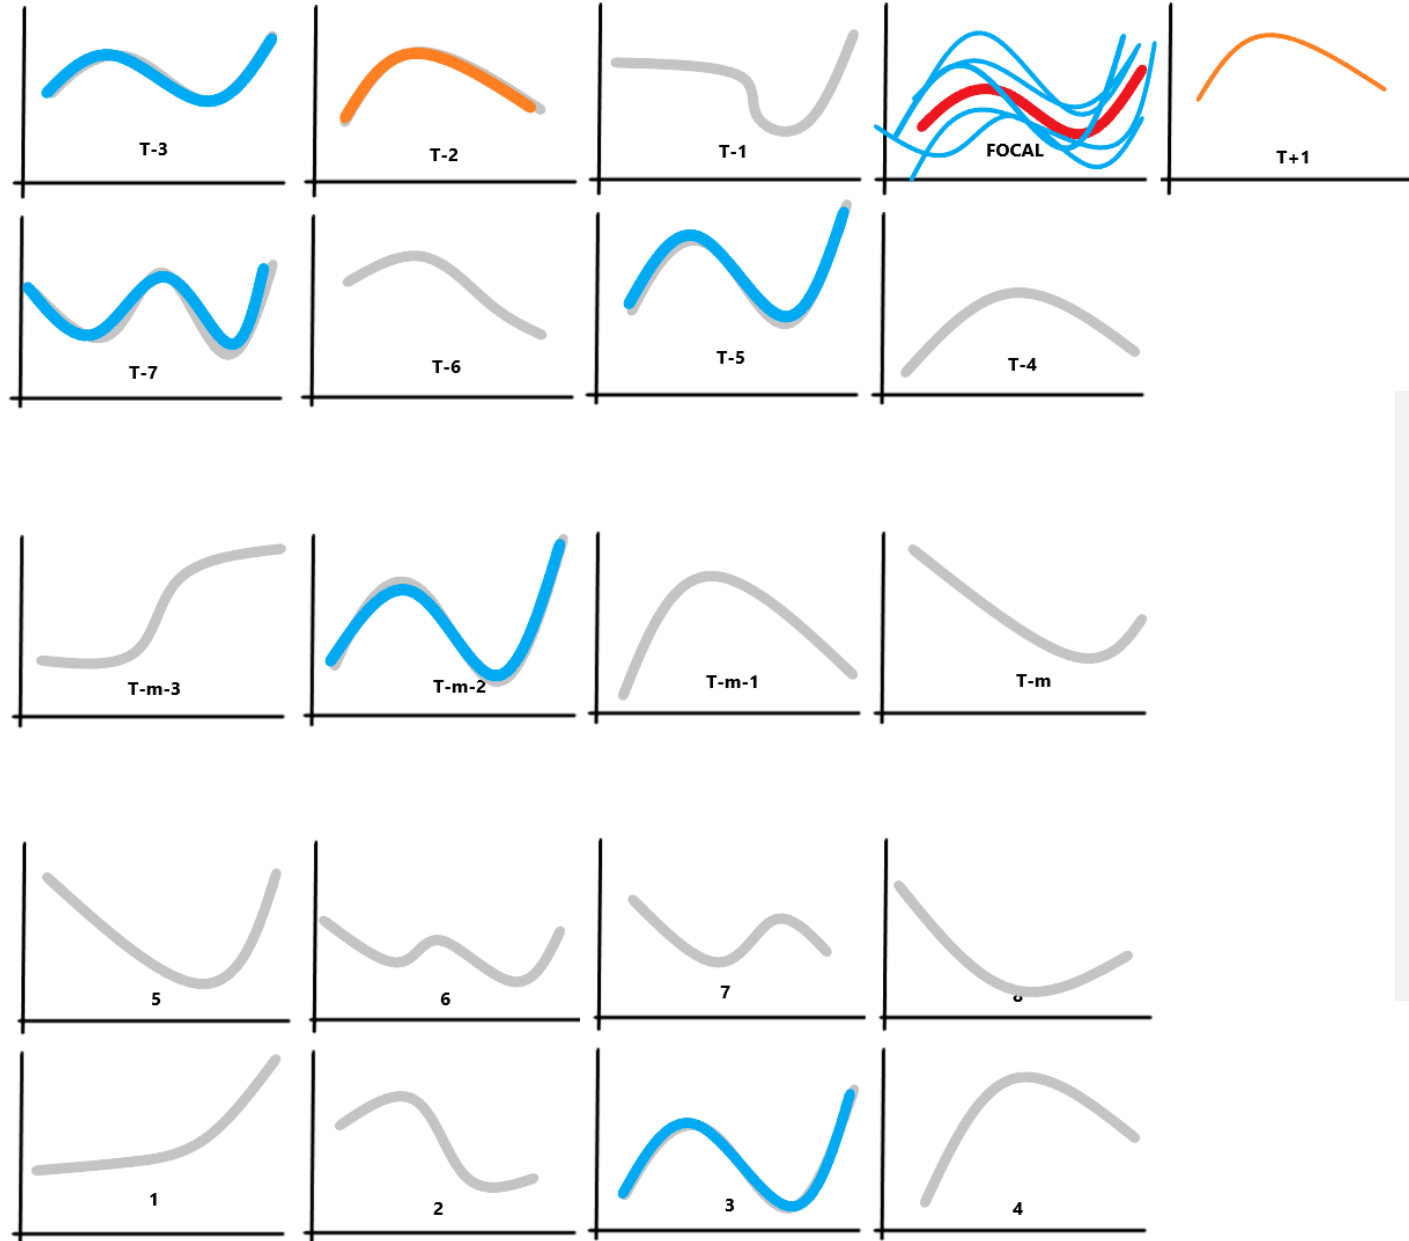
**Depth-based
functional
time series
forecasting**



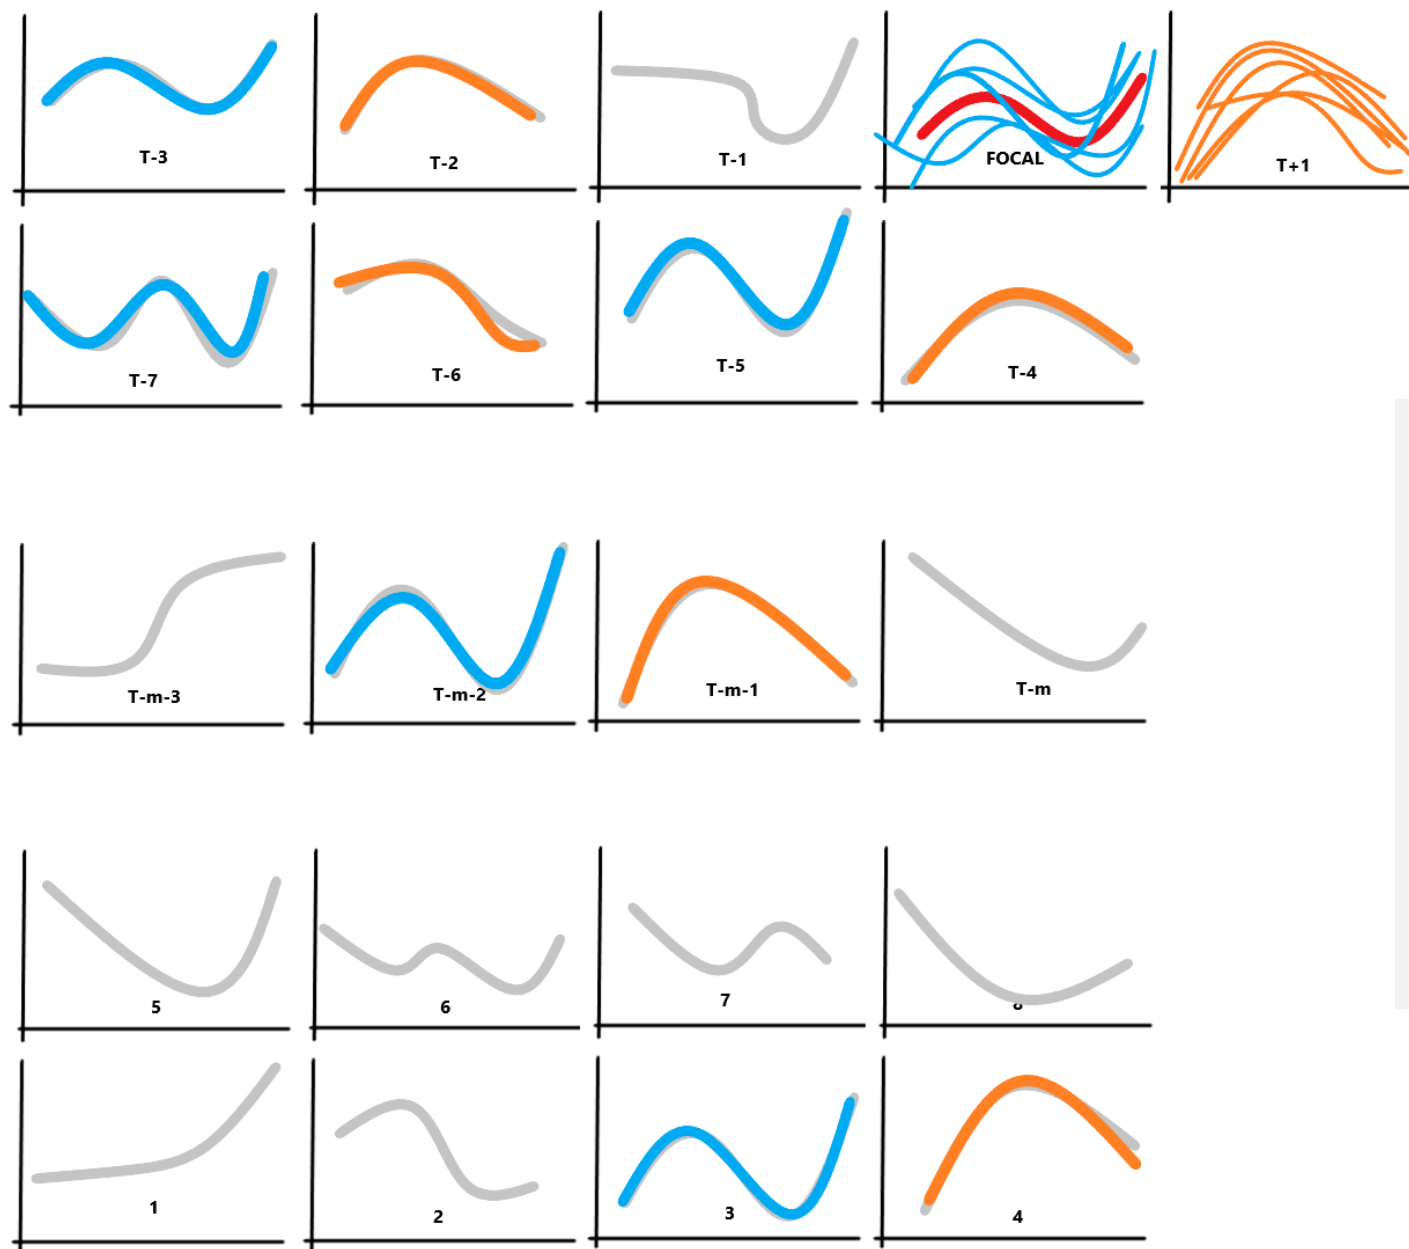
**Depth-based
functional
time series
forecasting**



**Depth-based
functional
time series
forecasting**



**Depth-based
functional
time series
forecasting**



**Depth-based
functional
time series
forecasting**

Resultados

Validación.

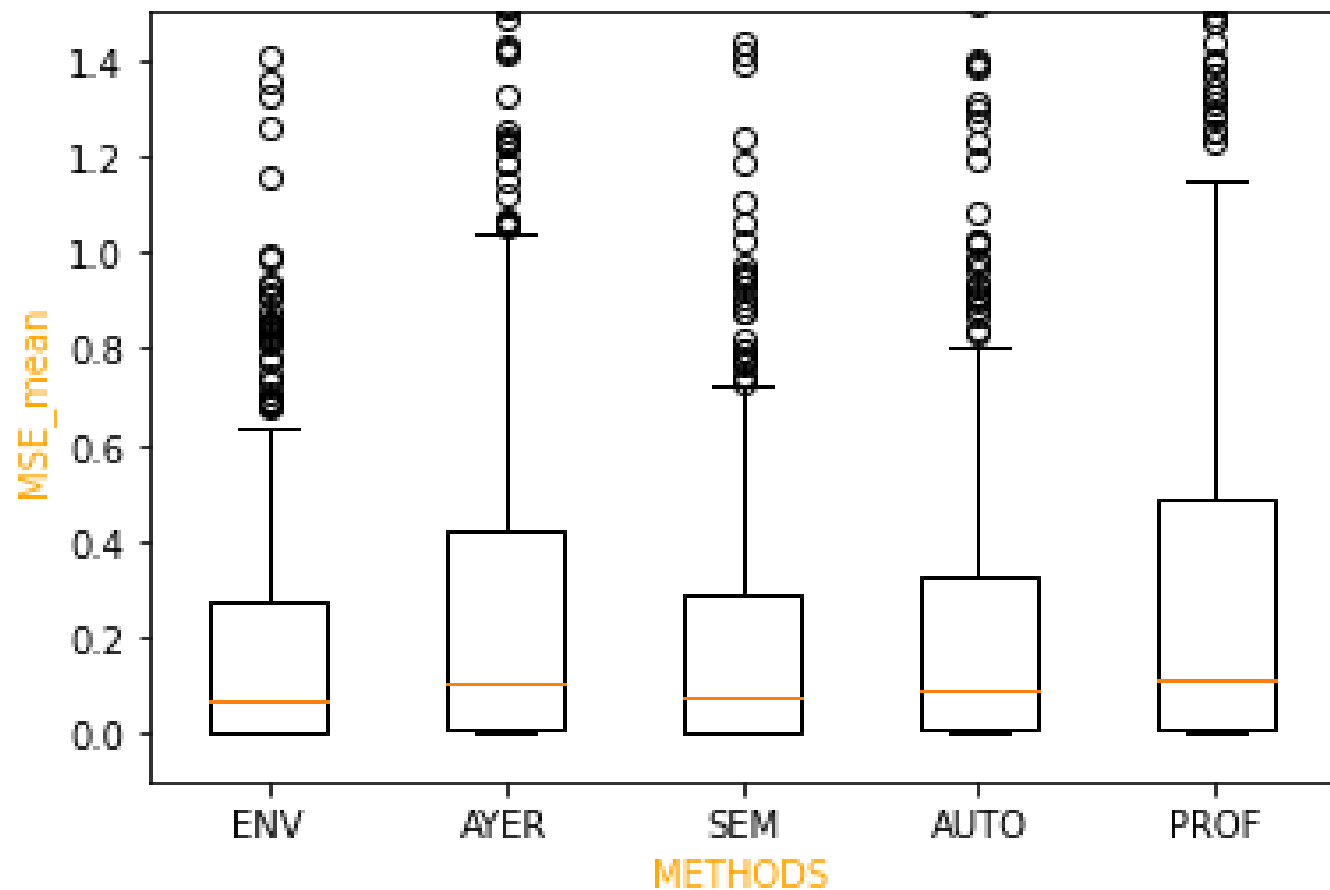
MÉTODOS BENCHMARKS

- 1) Repetición Ayer.
- 2) Media Hora Semanal.
- 3) Modelo Autorregresivo.
- 4) Profundidad Máxima.

EXPERIMENTOS					
SET	Inicio	Fin	Días	%	Validación
Training_1	01/01/2019	30/11/2019	334	91.51	Fijo
Test_1	01/12/2019	31/12/2019	31	8.49	Diario
Training_2	01/01/2019	31/03/2019	90	24.66	Rolling Window
Test_2	01/04/2019	31/12/2019	275	75.34	Diario

Resultados

Experimento 1: Performance MSE.




$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y})^2$$

Método	MSE mean
ENVOLTORIO	0.292
AYER	0.492
MEDIASEM	0.309
AUTOREG	0.397
PROF MAX	0.486

Resultados

Experimento 2: Performance MSE.




$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y})^2$$

Método	MSE mean
ENVOLTORIO	1.670
AYER	2.545
MEDIASEM	1.851
AUTOREG	6.848
PROF MAX	3.021

Resultados

Número de “victorias” para cada método.



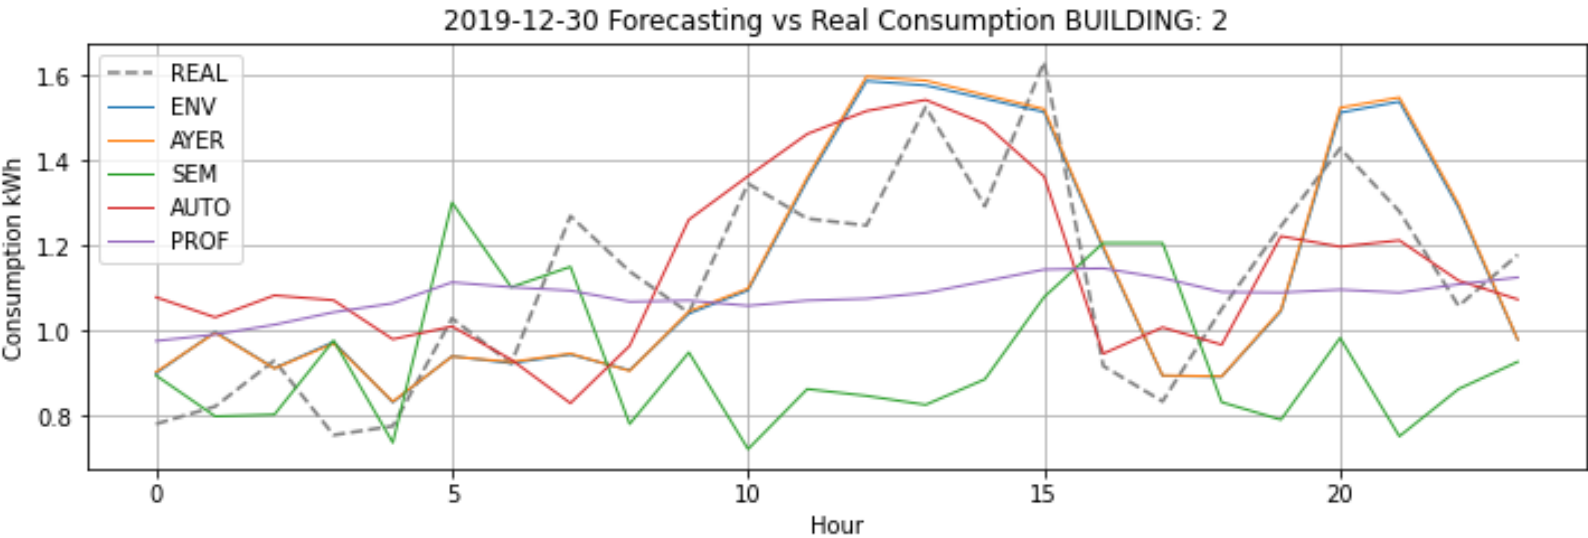
Experimento 1		
Método	Nº Edificios	%
ENVOLTORIO	261	52.30
AYER	13	2.61
MEDIASEM	155	31.06
AUTOREG	57	11.42
PROF MAX	13	2.61

Experimento 2		
Método	Nº Edificios	%
ENVOLTORIO	233	46.69
AYER	7	1.40
MEDIASEM	166	33.27
AUTOREG	91	18.24
PROF MAX	2	0.40


Resultados

Ejemplo consumo real vs predicción de un edificio (2019-12-30). Edificio 2.

Experimento 1



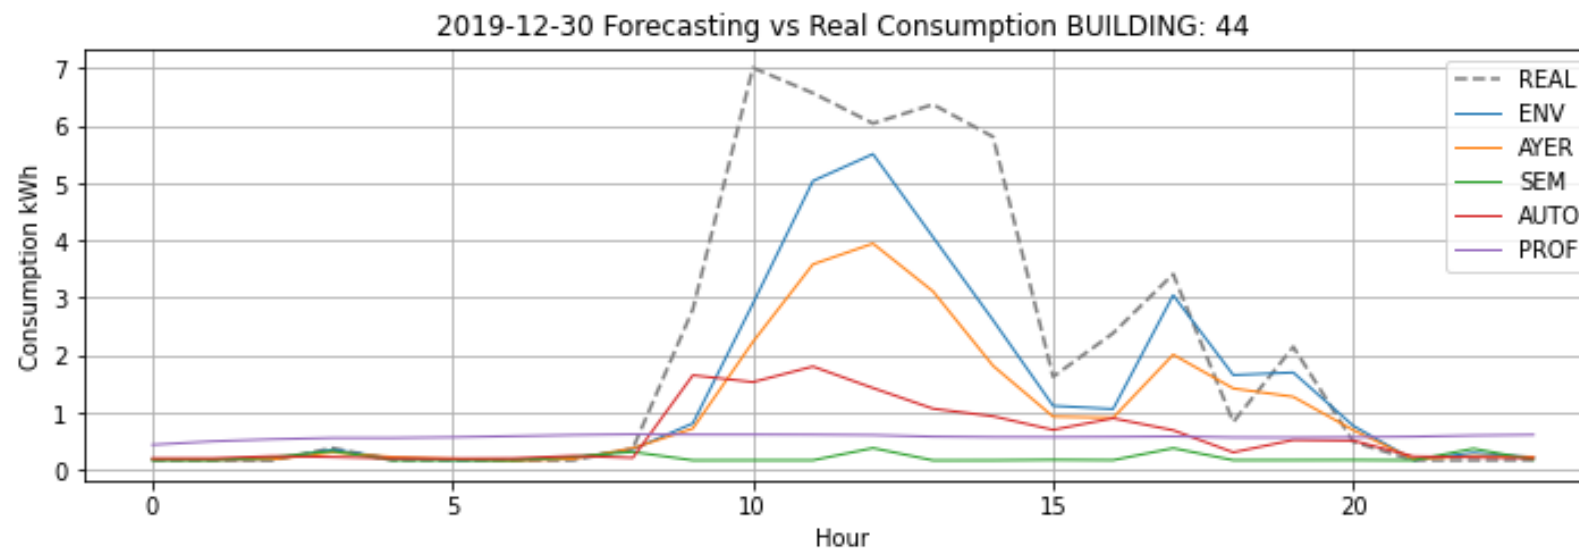
Experimento 2




Resultados

Ejemplo consumo real vs predicción de un edificio (2019-12-30). Edificio 44.

Experimento 1




Experimento 2



Resultados


Ejemplo consumo real vs predicción de un edificio (test-set). Edificio 2.

Experimento 1



MSE = 0.07

Experimento 2




MSE = 0.25

Resultados


Ejemplo consumo real vs predicción de un edificio (test-set). Edificio 44.

Experimento 1



MSE = 1.26

Experimento 2




MSE = 1.02

Resultados

Próximos pasos.


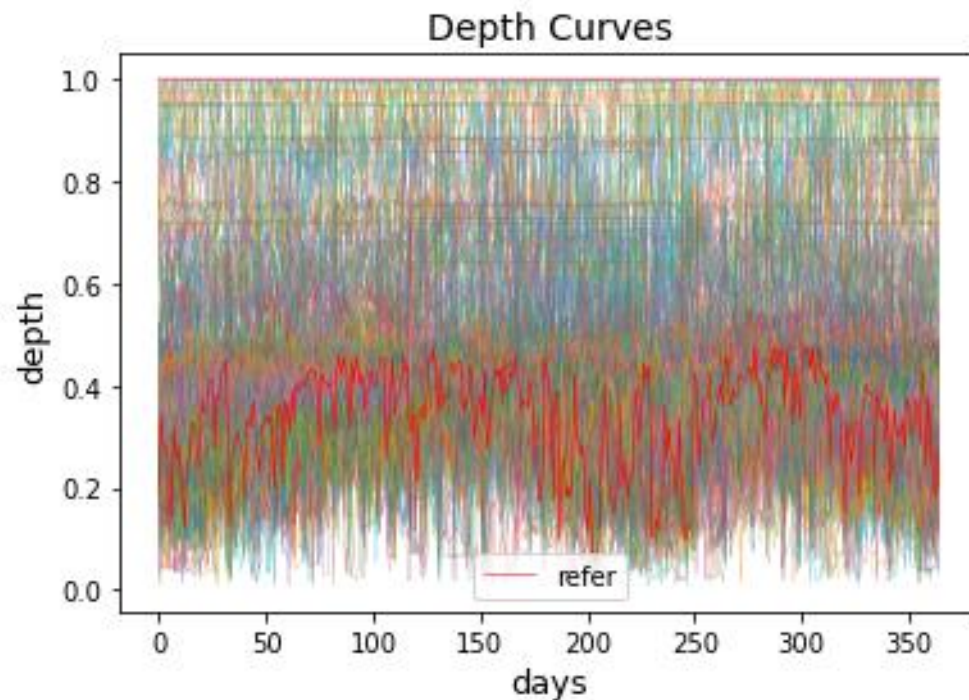
- Análisis edificio a edificio → Combinar la información entre edificios.
- Mejorar la precisión del algoritmo con una **estrategia de clustering** de edificios.
 - ✓ Ampliar el histórico de datos.
 - ✓ Aportar información adicional.
 - ✓ Minimizar el impacto de la heterogeneidad de los datos.
 - ✓ Mayor robustez del método.
 - ✓ Superar edificios conflictivos.



Línea de Investigación

Clustering: Time Series of Depth [7].


- Captar la **evolución**, la **magnitud** y la **forma** de las FTS a través de la profundidad.
- Definición de “k” clusters con “n” edificios.



Línea de Investigación

Clustering: Casos de uso.

- ✓ **Segmentación** de portfolios de instalaciones.
- ✓ **Agregación** de consumidores.
- ✓ Programas de **respuesta a la demanda**.
- ✓ Prospección de **comunidades** energéticas.
- ✓ Escalar medidas de **eficiencia energética**.
- ✓ Detección de edificios con **consumos atípicos**.



Conclusiones

- **Prestaciones superiores** a los métodos *benchmarks*.
- Detección precisa de patrones irregulares y **valores atípicos**.
- **Optimización** en la toma de decisiones y gestión de recursos energéticos.
- Puesta en valor de los **datos**.
- Servicio alineado con el **mercado**.
- Solución tecnológica **flexible**.

Referencias

- [1] J. O. Ramsay & B. W. Silverman, «Functional data analysis, » 2nd edition, Springer, New York, 2005.
- [2] G. Aneiros, I. Horová, M. Huskova & P. Vieu, «On functional data analysis and related topics, » Journal of Multivariate Analysis, vol. 189, 2022. <https://doi.org/10.1016/j.jmva.2021.104861>.
- [3] S. Makridakis, E. Spiliotis, V. Assimakopoulos, «Statistical and machine learning forecasting methods: Concerns and ways forward, » Plos One, vol. 13, no. 3, pp 1–26, 2018. <https://doi.org/10.1371/journal.pone.0194889>.
- [4] A. Elías, R. Jiménez & H. Shang, «On Projection Methods for Functional Time Series Forecasting, » Journal of Multivariate Analysis, vol. 189, 2022. <https://doi.org/10.1016/j.jmva.2021.104890>.
- [5] I. Gijbels & S. Nagy, «On a General Definition of Depth for Functional Data, » Statist. Sci., vol. 32, no. 4, pp. 630 - 639, 2017. <https://doi.org/10.1214/17-STS625>.
- [6] S.López-Pintado & J. Romo, «On the concept of depth for functional data, » J. Am. Stat. Assoc.: Theory Methods, vol. 104 (486), pp. 718–734, 2009. <https://doi.org/10.1198/jasa.2009.0108>.
- [7] A. Elías, J. M. Morales & S. Pineda, «A Functional Data Analysis Approach to Evolution Outlier Mining for Grouped Smart Meters, » [En línea]. <https://arxiv.org/abs/2107.01144>.

GRACIAS

Forecasting the energy consumption of multiple buildings



oasys.uma.es

PhD Candidate
Jesús Huete Cubillo

jhuete@uma.es
[linkedin.com/in/jesushuete](https://www.linkedin.com/in/jesushuete)

Bettergy

bettergy.es